Flux : Pig et Pig-Latin

Question 12 : Lisez les codes suivants, déduisez-en le résultat qu'ils doivent générer. Vérifiez ensuite en les exécutant qu'ils réalisent bien ce que vous avez deviné. Il vous est conseillé dans un premier temps de faire fonctionner le programme pas à pas avec grunt (en affichant les relations intermédiaires avec DUMP et leurs métadonnées avec DESCRIBE au fur et à mesure de l'exécution) :

Script req-etu1 : il va afficher le numéro étudiant, le module et la note des étudiants ayant une note inférieure à 10 en supprimant les doublons et en ordonnant par ordre de numero_etudiant.

vérification : effectivement c'est ce qu'on a dit

```
2024-04-25 11:34:23,533 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSyst
emImpl - JobTracker metrics system already initialized!
2024-04-25 11:34:23,571 [main] INFO  org.apache.pig.backend.hadoop.executionengi
ne.mapReduceLayer.MapReduceLauncher - Success!
2024-04-25 11:34:23,599 [main] INFO  org.apache.hadoop.conf.Configuration.deprec
ation - fs.default.name is deprecated. Instead, use fs.defaultFS
2024-04-25 11:34:23,612 [main] INFO  org.apache.hadoop.conf.Configuration.deprec
ation - io.bytes.per.checksum is deprecated. Instead, use dfs.bytes-per-checksum
2024-04-25 11:34:23,612 [main] WARN  org.apache.pig.data.SchemaTupleBackend - Sc
hemaTupleBackend has already been initialized
2024-04-25 11:34:23,664 [main] INFO  org.apache.hadoop.mapreduce.lib.input.FileI
nputFormat - Total input files to process : 1
2024-04-25 11:34:23,664 [main] INFO  org.apache.pig.backend.hadoop.executionengi
ne.util.MapRedUtil - Total input paths to process : 1
(111111,PSSR,9.5)
(111111,DCA,3.5)
(111111,DCA,0.25)
(111111,IA,8.75)
(222222,PSSR,7.5)
(222222,DCA,2.0)
(222222,DCA,1.5)
(222222,IA,9.0)
(222222,IA,9.5)
(333333,DCA,6.5)
grunt>
grunt>
```

Script req-etu2 : traite les notes des étudiants, calcule la moyenne pour chaque étudiant pour chaque module, filtre les résultats pour ne garder que les moyennes inférieures à 8, et affiche ces résultats.

vérification : effectivement c'est juste

```
emImpl - JobTracker metrics system already initialized!
2024-04-26 14:09:19,447 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSyst
emImpl - JobTracker metrics system already initialized!
2024-04-26 14:09:19,467 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSyst
emImpl - JobTracker metrics system already initialized!
2024-04-26 14:09:19,471 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSyst
emImpl - JobTracker metrics system already initialized!
2024-04-26 14:09:19,507 [main] INFO  org.apache.pig.backend.hadoop.executionengi
ne.mapReduceLayer.MapReduceLauncher - Success!
2024-04-26 14:09:19,538 [main] INFO  org.apache.hadoop.conf.Configuration.deprec
ation - fs.default.name is deprecated. Instead, use fs.defaultFS
2024-04-26 14:09:19,545 [main] INFO  org.apache.hadoop.conf.Configuration.deprec
ation - io.bytes.per.checksum is deprecated. Instead, use dfs.bytes-per-checksum
2024-04-26 14:09:19,555 [main] WARN  org.apache.pig.data.SchemaTupleBackend - Sc
hemaTupleBackend has already been initialized
2024-04-26 14:09:19,604 [main] INFO  org.apache.hadoop.mapreduce.lib.input.FileI
nputFormat - Total input files to process : 1
2024-04-26 14:09:19,604 [main] INFO  org.apache.pig.backend.hadoop.executionengi
ne.util.MapRedUtil - Total input paths to process : 1
(111111,DCA,1.875)
(222222,DCA,1.75)
(222222,PSSR,7.5)
grunt>
grunt>
```

Script req-etu3 : affiche les prénoms et noms des étudiants, ainsi que les détails de chaque module, y compris les examens passés et les notes obtenues. Ce script combine les données des fichiers "notes.txt" et "etudiants.txt" en associant les informations des étudiants avec leurs résultats académiques.

```
ne.util.MapRedUtil - Total input paths to process : 1
(Harry,Cover,COO,1,14.0)
(Harry,Cover,DCA,1,0.25)
(Harry,Cover,DCA,2,3.5)
(Harry,Cover,BDA,1,11.0)
(Harry,Cover,IA,1,10.5)
(Harry,Cover,IA,2,8.75)
(Harry,Cover,PSSR,1,9.5)
(John,Doeuf,DCA,2,2.0)
(John,Doeuf,PSSR,1,7.5)
(John,Doeuf,IA,2,9.0)
(John,Doeuf,IA,1,9.5)
(John,Doeuf,DCA,1,1.5)
(John,Doeuf,COO,1,12.0)
(John,Doeuf,BDA,1,13.0)
(Jacques,Selere,BDA,1,17.0)
(Jacques,Selere,COO,1,15.0)
(Jacques,Selere,DCA,1,6.5)
(Jacques,Selere,DCA,2,11.0)
(Jacques,Selere,IA,1,14.0)
(Jacques,Selere,IA,2,15.0)
(Jacques,Selere,PSSR,1,10.0)
grunt>
grunt>
```

Question 13 : En vous inspirant des exemples précédents, écrivez un script pig permettant d'afficher pour chaque matière la moins bonne note, la moyenne des notes et la meilleure note obtenue dans cette matière lors du premier examen

req-etu4.pig

```
-- Script req-etu4.pig
-- afficher pour chaque matiere la moins bonne note, la moyenne des notes
-- et la meilleure note du premier examen.
R1 = LOAD 'notes.txt' USING PigStorage('\t')
     AS (num_etu : int, module : chararray, num_exam : int, note : double) ;
-- on filtre pour garder uniquement les notes du premier examen
R2 = FILTER R1 BY (num_exam == 1) ;
-- on regroupe par module
R3 = GROUP R2 BY module ;
-- pour chaque matiere, on recupere la moins bonne note et la meilleure note, et on compte
-- le nombre de note par matiere et on fait la somme des notes
R4 = FOREACH R3 GENERATE
                        FLATTEN (group) as module,
                        COUNT (R2) as compteur,
                        SUM (R2.note) as total,
                        MIN(R2.note) as min,
                        MAX(R2.note) as max;
-- on affiche pour chaque matiere, son nom, sa moins bonne note, sa meilleure note et sa moyenne
R5 = FOREACH R4 GENERATE module, min, (total/compteur), max;
dump R5 ;
```

Résultat :

```
mpl - JobTracker metrics system already initialized!
2024-04-27 11:52:09,338 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSystemI
mpl - JobTracker metrics system already initialized!
2024-04-27 11:52:09,343 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSystemI
mpl - JobTracker metrics system already initialized!
2024-04-27 11:52:09,421 [main] INFO  org.apache.pig.backend.hadoop.executionengine.
mapReduceLayer.MapReduceLauncher - Success!
2024-04-27 11:52:09,436 [main] INFO  org.apache.hadoop.conf.Configuration.deprecati
on - fs.default.name is deprecated. Instead, use fs.defaultFS
2024-04-27 11:52:09,447 [main] INFO  org.apache.hadoop.conf.Configuration.deprecati
on - io.bytes.per.checksum is deprecated. Instead, use dfs.bytes-per-checksum
2024-04-27 11:52:09,455 [main] WARN  org.apache.pig.data.SchemaTupleBackend - Schem
aTupleBackend has already been initialized
2024-04-27 11:52:09,647 [main] INFO  org.apache.hadoop.mapreduce.lib.input.FileInpu
tFormat - Total input files to process : 1
2024-04-27 11:52:09,647 [main] INFO  org.apache.pig.backend.hadoop.executionengine.
util.MapRedUtil - Total input paths to process : 1
(IA,9.5,11.333333333333334,14.0)
(BDA,11.0,13.666666666666666,17.0)
(COO,12.0,13.666666666666666,15.0)
(DCA,0.25,2.75,6.5)
(PSSR,7.5,9.0,10.0)
grunt>
grunt>
```

Que fait le script PIG suivant ?

Le script PIG "req-etu5b.pig" commence par enregistrer un fichier JAR nommé "tp.jar" pour utiliser des fonctions externes. Ensuite, il charge les données des étudiants à partir du fichier "etudiants.txt", en les séparant par des tabulations. La transformation des données est effectuée avec l'opération FOREACH, où chaque enregistrement de la relation est passé à une fonction "Majuscule" définie dans le fichier JAR. Cette fonction convertit les prénoms et noms des étudiants en majuscules. Le résultat final est affiché à l'aide de la commande DUMP.

```
2024-04-27 15:37:28,541 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSystem
Impl - JobTracker metrics system already initialized!
2024-04-27 15:37:28,554 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSystem
Impl - JobTracker metrics system already initialized!
2024-04-27 15:37:28,568 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSystem
Impl - JobTracker metrics system already initialized!
2024-04-27 15:37:28,606 [main] INFO  org.apache.pig.backend.hadoop.executionengine
.mapReduceLayer.MapReduceLauncher - Success!
2024-04-27 15:37:28,710 [main] INFO  org.apache.hadoop.conf.Configuration.deprecat
ion - fs.default.name is deprecated. Instead, use fs.defaultFS
2024-04-27 15:37:28,712 [main] INFO  org.apache.hadoop.conf.Configuration.deprecat
ion - io.bytes.per.checksum is deprecated. Instead, use dfs.bytes-per-checksum
2024-04-27 15:37:28,712 [main] WARN  org.apache.pig.data.SchemaTupleBackend - Sche
maTupleBackend has already been initialized
2024-04-27 15:37:29,014 [main] INFO  org.apache.hadoop.mapreduce.lib.input.FileInp
utFormat - Total input files to process : 1
2024-04-27 15:37:29,014 [main] INFO  org.apache.pig.backend.hadoop.executionengine
.util.MapRedUtil - Total input paths to process : 1
(111111,HARRY,COVER)
(222222,JOHN,DOEUF)
(333333,JACQUES,SELERE)
(444444,JEAN,BREILLE)
grunt>
grunt>
```

En utilisant le programme FormatDate.java, écrivez un script PIG permettant d'afficher les étudiants par mois de naissance.

req-etu6.pig

```
REGISTER ./tp.jar ;
R1 = LOAD 'etudiants.txt' USING PigStorage('\t')
     AS (num_etu : int, prenom : chararray, nom : chararray, date_naissance : chararray) ;

-- Utilisation de la fonction FormatDate pour extraire le mois de naissance
R2 = FOREACH R1 GENERATE tp.FormatDate(date_naissance)
     AS R2: bag{tuple(id: int, jour: chararray, moi: chararray, annee: chararray)};

-- Déplier le sac de tuples individuels
R3 = FOREACH R2 GENERATE FLATTEN($0)
     AS (id: int, jour: chararray, moi: chararray, annee: chararray);

-- Regroupement des étudiants par mois de naissance
R4 = GROUP R3 BY moi;
DUMP R4;
```

Résultat :

```
2024-04-27 16:43:13,802 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSystem
Impl - JobTracker metrics system already initialized!
2024-04-27 16:43:13,821 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSystem
Impl - JobTracker metrics system already initialized!
2024-04-27 16:43:13,879 [main] WARN  org.apache.hadoop.metrics2.impl.MetricsSystem
Impl - JobTracker metrics system already initialized!
2024-04-27 16:43:13,990 [main] INFO  org.apache.pig.backend.hadoop.executionengine
.mapReduceLayer.MapReduceLauncher - Success!
2024-04-27 16:43:14,027 [main] INFO  org.apache.hadoop.conf.Configuration.deprecat
ion - fs.default.name is deprecated. Instead, use fs.defaultFS
2024-04-27 16:43:14,033 [main] INFO  org.apache.hadoop.conf.Configuration.deprecat
ion - io.bytes.per.checksum is deprecated. Instead, use dfs.bytes-per-checksum
2024-04-27 16:43:14,034 [main] WARN  org.apache.pig.data.SchemaTupleBackend - Sche
maTupleBackend has already been initialized
2024-04-27 16:43:14,895 [main] INFO  org.apache.hadoop.mapreduce.lib.input.FileInp
utFormat - Total input files to process : 1
2024-04-27 16:43:14,896 [main] INFO  org.apache.pig.backend.hadoop.executionengine
.util.MapRedUtil - Total input paths to process : 1
(01,{(0,03,01,1996),(0,28,01,1986)})
(07,{(0,18,07,1998)})
(08,{(0,06,08,1991)})
grunt>
grunt>
grunt>
```